

Metodologia CRISP-DM em Projetos de Dados

Guia Prático com Exemplos Detalhados por Etapa & Código Python Colab

Cross-Industry Standard Process for Data Mining
Aplicações em Indústria 4.0, Varejo, Finanças e Saúde | Plataforma FactoryHub 2026

O que é a Metodologia CRISP-DM?

- Padrão Internacional Global: A metodologia para desenvolvimento de projetos de Data Science e Machine Learning mais utilizada no mundo.
- Consórcio de Criadores: Desenvolvida por IBM (SPSS), DaimlerChrysler, NCR e OHRA nos anos 90.
- Ciclo Não-Linear & Flexível: Permite e incentiva retornar a etapas anteriores sempre que novas descobertas surgirem.
- Foco no Valor de Negócio: O sucesso técnico do algoritmo depende diretamente do retorno financeiro e operacional da organização.

Visão Geral das 6 Fases Cíclicas

Slide 03/15

1. Business Understanding

Definição de objetivos de negócio, limites e meta técnica.

2. Data Understanding

Coleta inicial, inspeção de dtypes, EDA e auditoria de nulos.

3. Data Preparation

Limpeza, imputação com Pandas, IQR e feature engineering (50-70% do tempo).

4. Modeling

Particionamento Treino/Teste, treinamento de algoritmos (Ex: Random Forest).

5. Evaluation

Validação do modelo contra os critérios objetivos e ROI do negócio.

6. Deployment

Implantação em produção (API REST, Cloud, Docker) e monitoramento.

Conceitos e Tarefas Principais

- Traduzir problemas de negócio em metas analíticas.
- Mapear recursos (equipe, hardware), restrições (LGPD) e riscos.
- Realizar análise de Custo-Benefício (ROI esperado).
- Definir critérios objetivos de sucesso de negócio.



Exemplo Prático Aplicado

Cenário: Fábrica Smart N1

- Problema: Paradas de esteira por quebra da prensa geram prejuízo de R\$ 50 mil/mês.
- Meta de Negócio: Reduzir em 20% o tempo de inatividade não planejada.
- Meta de Mineração de Dados: Prever falhas mecânicas com 2 horas de antecedência (Acurácia > 85% e Recall > 80%).

Conceitos e Tarefas Principais

- Coletar dados brutos (sensores, logs, bancos SQL, APIs).
- Descrever volume, tipos de dados (dtypes) e formatos.
- Explorar estatisticamente (Média, Mediana, Desvio Padrão).
- Auditar falhas de qualidade (nulos, outliers e ruídos).



Exemplo Prático Aplicado

Cenário: Telemetria de Sensores

- Coleta: Ingestão de 1.000 leituras de pressão (bar), temperatura (°C), vibração (mm/s) e rotação (RPM) via protocolo MQTT.
- Descoberta de Qualidade: Identificação de 15 leituras com valores ausentes (NaN) e 1 pico incorreto de 999°C por falha de sensor.

Conceitos e Tarefas Principais

- Consome entre 50% e 70% de todo o tempo do projeto.
- Limpeza de nulos (`fillna`) e eliminação de ruídos.
- Engenharia de Atributos (Feature Engineering).
- Integração de tabelas (Merge/Join) e normalização de escalas.



Exemplo Prático Aplicado

Cenário: Tratamento com Pandas em Python

- Imputação: Preenchimento das lacunas de pressão pela Mediana (6.0 bar) por ser imune a distorções.
- Remoção de Anomalias: Exclusão de registros com temperatura > 150°C pelo método IQR.
- Atributo Derivado: Criação da razão 'Temperatura / Pressão'.

Conceitos e Tarefas Principais

- Escolher algoritmos (Random Forest, XGBoost, KMeans).
- Garantir partição de dados em Treino e Teste (Ex: 70/30).
- Treinamento do modelo e ajuste de hiperparâmetros.
- Avaliação da acurácia técnica e matriz de confusão.



Exemplo Prático Aplicado

Cenário: Treinamento de Modelo

- Algoritmo Selecionado: Random Forest Classifier (100 árvores de decisão em paralelo).
- Execução: ``modelo.fit(X_train, y_train)``.
- Particionamento: Separação de 700 registros para treino e 300 para validação cega de teste.

Conceitos e Tarefas Principais

- Validar se o modelo atinge os objetivos reais de negócio.
- Revisão detalhada de todas as fases do projeto.
- Avaliar métricas de precisão, recall, F1-score e matriz de confusão.
- Tomada de decisão: Aprovar para Deploy ou Iterar.



Exemplo Prático Aplicado

Cenário: Validação de Resultados

- Resultado Técnico: Acurácia obtida de 89.2% e Recall de falhas de 84.5%.
- Avaliação de Negócio: O modelo atingiu o critério de sucesso! Estimativa de redução de 22% no tempo de inatividade da fábrica (economia de R\$ 55 mil/mês).
- Decisão: Aprovado para Implantação!

Fase 6: Deployment (Implementação em Produção)

Slide 09/15

Conceitos e Tarefas Principais

- Empacotamento da solução (API RESTful, Docker, GCP Cloud Run).
- Criação de Dashboards operacionais e alertas.
- Planejamento do monitoramento de Data Drift / Model Drift.
- Relatório final e entrega das lições aprendidas.



Exemplo Prático Aplicado

Cenário: Produção em Tempo Real

- Endpoint de API: Disponibilização da função ``predizer_status_maquina()`` servindo o chão de fábrica.
- Alerta: Ao detectar risco de falha > 75%, o sistema grava um alarme CRITICAL e emite notificação para a equipe de manutenção.

- Arquivo Disponibilizado: 'CRISP_DM_Exemplo_Colab.ipynb' na pasta do repositório.
- Execução End-to-End: Contém scripts testados que executam as 6 fases em sequência.
- Bibliotecas Utilizadas: Pandas, NumPy, Scikit-Learn, Matplotlib e Seaborn.
- Objetivo Pedagógico: Permitir que o aluno execute, altere parâmetros e visualize a matriz de confusão na nuvem gratuitamente.

Treinamento & Avaliação

```
```python
4. Modelagem
from sklearn.ensemble import RandomForestClassifier

modelo = RandomForestClassifier(n_estimators=100)
modelo.fit(X_train, y_train)

5. Avaliação
y_pred = modelo.predict(X_test)
print(classification_report(y_test, y_pred))
```
```

Implantação (Deploy)

```
```python
6. Função de Predição para Produção
def predizer_falha(pressao, temp, vib, rpm):
 dados = pd.DataFrame([{'pressao_bar': pressao,
 'temperatura_c': temp,
 'vibracao_mms': vib,
 'rotacao_rpm': rpm}])
 prob = modelo.predict_proba(dados)[0][1]
 return f'Alerta: Risco {prob*100:.1f}%'
```
```



Fases 1 a 3 (Negócio aos Dados)

- Negócio: Elevar vendas cruzadas (cross-selling) em 10%.
- Dados: Logs de navegação web + histórico de compras SQL.
- Preparação: Agregação por sessão e remoção de chamadas a imagens JPG/PNG.

Fases 4 a 6 (Modelagem ao Deploy)

- Modelagem: Algoritmo de Regras de Associação (C5.0 / Apriori).
- Avaliação: Teste A/B demonstrando aumento do ticket médio.
- Deploy: Motor de recomendação integrado ao carrinho de compras.



Estudo de Caso: Finanças (Fraudes) e Saúde

Slide 13/15



Detecção de Fraude Bancária

- Desafio: Analisar milhões de transações em milissegundos.
- Técnica: XGBoost com balanceamento de classe (SMOTE).
- Deploy: Endpoint gRPC de alta velocidade no barramento de pagamentos.



Saúde (Readmissão Hospitalar)

- Desafio: Identificar pacientes de risco em 30 dias após alta.
- Técnica: Regressão Logística interpretável (odds ratio).
- Deploy: Alertas no prontuário eletrônico para enfermagem.



O CRISP-DM no Ecossistema Smart N1

Slide 14/15

- Automação (OT): Leitura física de sensores na esteira e publicação MQTT.
- Ciência de Dados: Tratamento em Pandas, detecção de outliers pelo método IQR e testes inferenciais.
- DevOps: Empacotamento Docker e pipelines automatizadas de CI no GitHub Actions.
- Computação em Nuvem: Deploy do backend no GCP Cloud Run e monitoramento de custos com FinOps.

Conclusão e Principais Aprendizados

O CRISP-DM transforma dados brutos em valor real de negócios.

Execute o notebook 'CRISP_DM_Exemplo_Colab.ipynb' diretamente no Google Colab!
Dúvidas e Perguntas?