

Ciência de Dados

Revisão dos conceitos cobrados na P1



Decidir com métricas corretas

A prova conecta estatística descritiva, avaliação de classificadores, testes de hipótese e séries temporais.

Q10 anulada em todas as versões. O conceito foi mantido somente para aprendizagem e não deve gerar pontuação.

CRISP–DM e tipos de variáveis

A pergunta de negócio orienta a técnica

Avaliação	Na fase 5 do CRISP–DM, verifique se o modelo atende às metas do negócio antes da implantação.
Nominal	Categorias sem ordem, como identificadores e códigos.
Ordinal	Categorias ordenadas, como severidade baixa, média e alta.
Discreta	Contagens inteiras, como número de falhas.
Contínua	Medições em escala, como temperatura e pressão.

- CLASSIFICAÇÃO

Classe rara e custos assimétricos

Acurácia alta pode esconder um modelo inútil

Acurácia = $(VP + VN) / \text{total}$

Recall = $VP / (VP + FN)$

Precisão = $VP / (VP + FP)$

Falso negativo

Uma peça defeituosa é liberada. Pode provocar acidentes, recall e prejuízo.

Falso positivo

Uma peça boa é reprovada. Normalmente gera reinspeção e custo operacional.

Se apenas 0,1% das peças têm defeito, prever tudo como bom produz 99,9% de acurácia e 0% de recall.

- MÉTRICAS

Recall, precisão, acurácia e F1

Cada métrica responde a uma pergunta

Recall	Entre os positivos reais, quantos o modelo encontrou? Priorize quando falso negativo custa mais.
---------------	--

Precisão	Entre as previsões positivas, quantas estavam corretas? Importa quando falsos alarmes custam caro.
-----------------	--

Acurácia	Qual fração total foi classificada corretamente? Cuidado com classes desbalanceadas.
-----------------	--

F1	Média harmônica entre precisão e recall. Penaliza desequilíbrio entre as duas métricas.
-----------	---

$$F1 = 2 \times (Precisão \times Recall) / (Precisão + Recall)$$

Mediana, IQR e regra de Tukey

Valores extremos afetam medidas de maneiras diferentes

Mediana

Depende da posição central dos dados ordenados e resiste melhor a extremos.

IQR

Q3 - Q1 descreve os 50% centrais dos dados.

Média e desvio

Usam magnitudes e são deslocados por valores extremos, especialmente pelos desvios quadráticos.

$$\text{IQR} = Q3 - Q1$$

$$\text{Limite superior} = Q3 + 1,5 \times \text{IQR}$$

A: 90 °C. B: 80 °C. C: 125 bar. D: 75 mm. Um outlier superior fica estritamente acima do limite.

- INFERÊNCIA

Shapiro–Wilk e p–valor

A decisão é sobre rejeitar ou não H_0

Se $p < \alpha$: rejeitar H_0 de normalidade

Se $p \geq \alpha$: não rejeitar H_0

Versão A

0,018 < 0,05: rejeitar normalidade.

Versão B

0,082 > 0,05: não rejeitar H_0 .

Versão C

0,004 < 0,01: rejeitar normalidade.

Versão D

0,125 > 0,05: não rejeitar H_0 .

Não rejeitar H_0 não prova que os dados são normais. Significa que o teste não encontrou evidência suficiente contra a normalidade.

- SÉRIES TEMPORAIS

Tendência, sazonalidade e ruído

A decomposição separa estruturas com comportamentos distintos

Tendência

Mudança de longo prazo no nível da série.

Sazonalidade

Padrão que se repete em intervalos regulares.

Ruído ou resíduo

Flutuação aleatória que permanece após explicar as estruturas principais.

- QUESTÃO ANULADA

Paradigmas de aprendizado

Conteúdo mantido apenas para estudo

Regressão linear

Aprendizado supervisionado com saída numérica contínua.

Árvore de classificação

Aprendizado supervisionado com saída em classes.

K-Means

Aprendizado não supervisionado para agrupamento.

PCA

Método não supervisionado para redução dimensional.

Motivo da anulação: a cobertura desses paradigmas antes da P1 era parcial. O conteúdo permanece como ampliação conceitual.

Matriz de confusão e custo do erro

Cada item vale 0,90

Item A

Defina FP como reprovar uma peça boa e FN como liberar uma peça defeituosa. Explique por que FN tende a ser mais grave no cenário industrial.

Item B

Mostre por que a acurácia é dominada pela classe majoritária. Cite recall, precisão, F1 e o custo dos erros como complementos.

A resposta precisa interpretar o cenário. Escrever apenas as fórmulas não explica o risco operacional.

- DISCURSIVA Q12

Robustez e decisão sobre normalidade

Cada item vale 0,90

Item A

Compare mediana e IQR com média e desvio padrão. Robustez significa menor sensibilidade, não imunidade absoluta.

Item B

Explique a regra de decisão pelo p-valor e como ela orienta pressupostos, transformações ou métodos robustos e não paramétricos.

Por que essas justificativas estão corretas

A métrica precisa representar o risco da decisão

Classe rara

A classe majoritária domina a acurácia. Por isso um modelo pode acertar quase tudo e ainda ignorar todos os defeitos.

Recall

O denominador contém todos os positivos reais. A métrica responde quantos defeitos escaparam da detecção.

Mediana e IQR

Usam posições na ordenação, não a magnitude de todos os valores. Um extremo desloca menos essas medidas.

Shapiro-Wilk

O p-valor mede compatibilidade com H_0 . Um valor alto significa evidência insuficiente para rejeitar, não prova de normalidade.

CRISP-DM

Um modelo tecnicamente bom só tem valor se atender ao objetivo e ao custo de erro definidos pelo negócio.

Dicionário de siglas

Termos usados na prova e na correção

CRISP-DM Cross-Industry Standard Process for Data Mining

EDA Exploratory Data Analysis, análise exploratória de dados

VP Verdadeiro positivo

VN Verdadeiro negativo

FP Falso positivo

FN Falso negativo

IQR Interquartile Range, intervalo interquartil

H0 Hipótese nula

F1 Média harmônica entre precisão e recall

PCA Principal Component Analysis

ML Machine Learning, aprendizado de máquina

K-Means Algoritmo de agrupamento por centroides

- SÍNTESE

Erros que reduzem a pontuação

Frases que precisam de correção

Acurácia alta garante bom modelo

Em classe rara, o recall pode ser zero.

p alto prova normalidade

O teste apenas não rejeita H_0 .

Todo valor no limite é outlier

A regra superior usa valor estritamente maior.

Robusto significa imune

Mediana e IQR ainda podem mudar.

Mapa de revisão

Quatro perguntas para escolher a ferramenta

1 Qual é a **meta de negócio**?

2 Qual erro tem **maior custo**?

3 Os dados têm **extremos ou desbalanceamento**?

4 Qual conclusão o **teste estatístico** permite?