

Gabarito P1

Ciência de Dados

Versões A, B, C e D • Respostas esperadas e vínculo com o material

Fonte da prova: provas/Ciencia_de_Dados/P1 Ciencia de Dados.docx

Leitura: S01, S02 etc. identificam os arquivos de aula listados ao final. G identifica o guia de estudo e R, o apoio indicado. O vínculo comprova presença no material disponível, não a realização efetiva da aula.

Consulta rápida — questões objetivas

Versão	01	02	03	04	05	06	07	08	09	10
A	C	B	B	A	C	A	A	B	A	ANUL.
B	B	C	A	A	C	B	A	B	C	ANUL.
C	B	C	A	B	A	C	B	A	A	ANUL.
D	A	B	C	B	C	A	A	B	C	ANUL.

Pontuação: Q01–08: 0,60 cada; Q09–10: 0,80 cada; Q11–12: 1,80 cada (0,90 por item). Total: 10,0.

Observações para correção

Questão 10 ANULADA nas versões A, B, C e D. A resposta conceitual e a sequência de associação de cada versão foram mantidas para estudo do aluno. Na versão C, a sequência correta é 1–3–4–2 e não consta nas alternativas.

Questão 10, todas as versões: a Semana 04 oferece base parcial sobre modelagem supervisionada, mas não foi localizada cobertura explícita de K-Means e PCA nos notebooks disponíveis. O README prevê aprendizado supervisionado na Semana 12 e não supervisionado na Semana 13; PCA não foi localizado. Não é possível atribuir integralmente essa questão a uma aula anterior à P1.

ANUL. = questão anulada em todas as versões; resposta conceitual mantida apenas para fins de aprendizagem.

As respostas discursivas, comuns em conteúdo às quatro versões, estão reunidas após os gabaritos por versão. Aceitar formulações equivalentes que contemplem os conceitos essenciais.

Versão A

Questões objetivas e aula correspondente

Q01 · Alternativa C — Avaliação no CRISP-DM

Verificar se o modelo atende às metas de negócio antes de implantá-lo: fase 5, Avaliação.

Aula/material: S01, §3, fase 5; S04, §3

Q02 · Alternativa B — Custos assimétricos e recall

Priorizar recall = $VP/(VP+FN)$, reduzindo falhas não detectadas; tolerar falsos alarmes conforme o custo de inspeção.

Aula/material: S01, custos assimétricos; S02, §2

Q03 · Alternativa B — Acurácia em classes raras

$99.900/100.000 = 99,9\%$. Recall = 0%: nenhum defeito foi detectado.

Aula/material: S02, §2

Q04 · Alternativa A — Tipos de variáveis

Identificador: nominal; severidade: ordinal; contagem: discreta; medição física: contínua. Respeitar a ordem do enunciado.

Aula/material: S01, §1.2

Q05 · Alternativa C — Medida robusta de centro

Mediana: menos sensível a valores extremos, representando melhor o valor típico nesse cenário.

Aula/material: S01, §1.3; S03, §2.1

Q06 · Alternativa A — Boxplot e regra de Tukey

$IQR = 60 - 40 = 20$ °C; limite = $60 + 1,5 \times 20 = 90$ °C. Outliers superiores ficam estritamente acima do limite.

Aula/material: S03, §2.1

Q07 · Alternativa A — Teste de Shapiro-Wilk

$0,018 < 0,05$: rejeitar H_0 de normalidade.

Aula/material: S05, p-valor e testes de normalidade

Q08 · Alternativa B — Componentes de séries temporais

Tendência (mudança de longo prazo), sazonalidade (repetição regular) e ruído/resíduo (flutuação aleatória).

Aula/material: S07, §1.1

Q09 · Alternativa A — Associação de métricas

Sequência: 3–2–1–4. Recall: $VP/(VP+FN)$; precisão: $VP/(VP+FP)$; acurácia: $(VP+VN)/total$; F1: média harmônica de precisão e recall.

Aula/material: S02, §2

Q10 · ANULADA — Paradigmas de aprendizado

Resposta conceitual para estudo do aluno (questão anulada): Sequência: 3–2–1–4. Regressão linear: supervisionado/valor contínuo; árvore de classificação: supervisionado/classe; K-Means: não supervisionado/agrupamento; PCA: não supervisionado/redução dimensional.

Aula/material: Cobertura parcial: S04, §2. Ver ressalva na página inicial.

Q11 e Q12: respostas e fontes por subitem na seção seguinte.

Versão B

Questões objetivas e aula correspondente

Q01 · Alternativa B — Custos assimétricos e recall

Priorizar recall = $VP/(VP+FN)$, reduzindo falhas não detectadas; tolerar falsos alarmes conforme o custo de inspeção.

Aula/material: S01, custos assimétricos; S02, §2

Q02 · Alternativa C — Teste de Shapiro-Wilk

$0,082 > 0,05$: não rejeitar H_0 ; isso não comprova normalidade.

Aula/material: S05, p-valor e testes de normalidade

Q03 · Alternativa A — Acurácia em classes raras

$199.950/200.000 = 99,975\%$. Recall = 0%: nenhum defeito foi detectado.

Aula/material: S02, §2

Q04 · Alternativa A — Avaliação no CRISP-DM

Verificar se o modelo atende às metas de negócio antes de implantá-lo: fase 5, Avaliação.

Aula/material: S01, §3, fase 5; S04, §3

Q05 · Alternativa C — Tipos de variáveis

Identificador: nominal; severidade: ordinal; contagem: discreta; medição física: contínua. Respeitar a ordem do enunciado.

Aula/material: S01, §1.2

Q06 · Alternativa B — Boxplot e regra de Tukey

$IQR = 50 - 30 = 20$ °C; limite = $50 + 1,5 \times 20 = 80$ °C. Outliers superiores ficam estritamente acima do limite.

Aula/material: S03, §2.1

Q07 · Alternativa A — Medida robusta de centro

Mediana: menos sensível a valores extremos, representando melhor o valor típico nesse cenário.

Aula/material: S01, §1.3; S03, §2.1

Q08 · Alternativa B — Componentes de séries temporais

Tendência (mudança de longo prazo), sazonalidade (repetição regular) e ruído/resíduo (flutuação aleatória).

Aula/material: S07, §1.1

Q09 · Alternativa C — Associação de métricas

Sequência: 2–3–1–4. Recall: $VP/(VP+FN)$; precisão: $VP/(VP+FP)$; acurácia: $(VP+VN)/total$; F1: média harmônica de precisão e recall.

Aula/material: S02, §2

Q10 · ANULADA — Paradigmas de aprendizado

Resposta conceitual para estudo do aluno (questão anulada): Sequência: 2–3–1–4. Regressão linear: supervisionado/valor contínuo; árvore de classificação: supervisionado/classe; K-Means: não supervisionado/agrupamento; PCA: não supervisionado/redução dimensional.

Aula/material: Cobertura parcial: S04, §2. Ver ressalva na página inicial.

Q11 e Q12: respostas e fontes por subitem na seção seguinte.

Versão C

Questões objetivas e aula correspondente

Q01 · Alternativa B — Custos assimétricos e recall

Priorizar recall = $VP/(VP+FN)$, reduzindo falhas não detectadas; tolerar falsos alarmes conforme o custo de inspeção.

Aula/material: S01, custos assimétricos; S02, §2

Q02 · Alternativa C — Avaliação no CRISP-DM

Verificar se o modelo atende às metas de negócio antes de implantá-lo: fase 5, Avaliação.

Aula/material: S01, §3, fase 5; S04, §3

Q03 · Alternativa A — Acurácia em classes raras

$499.750/500.000 = 99,95\%$. Recall = 0%: nenhum defeito foi detectado.

Aula/material: S02, §2

Q04 · Alternativa B — Tipos de variáveis

Identificador: nominal; severidade: ordinal; contagem: discreta; medição física: contínua. Respeitar a ordem do enunciado.

Aula/material: S01, §1.2

Q05 · Alternativa A — Medida robusta de centro

Mediana: menos sensível a valores extremos, representando melhor o valor típico nesse cenário.

Aula/material: S01, §1.3; S03, §2.1

Q06 · Alternativa C — Boxplot e regra de Tukey

$IQR = 80 - 50 = 30$ bar; limite = $80 + 1,5 \times 30 = 125$ bar. Outliers superiores ficam estritamente acima do limite.

Aula/material: S03, §2.1

Q07 · Alternativa B — Teste de Shapiro-Wilk

$0,004 < 0,01$: rejeitar H_0 de normalidade.

Aula/material: S05, p-valor e testes de normalidade

Q08 · Alternativa A — Componentes de séries temporais

Tendência (mudança de longo prazo), sazonalidade (repetição regular) e ruído/resíduo (flutuação aleatória).

Aula/material: S07, §1.1

Q09 · Alternativa A — Associação de métricas

Sequência: 3–2–1–4. Recall: $VP/(VP+FN)$; precisão: $VP/(VP+FP)$; acurácia: $(VP+VN)/total$; F1: média harmônica de precisão e recall.

Aula/material: S02, §2

Q10 · ANULADA — Paradigmas de aprendizado

Resposta conceitual para estudo do aluno (questão anulada): Sequência: 1–3–4–2. Regressão linear: supervisionado/valor contínuo; árvore de classificação: supervisionado/classe; K-Means: não supervisionado/agrupamento; PCA: não supervisionado/redução dimensional.

Aula/material: Cobertura parcial: S04, §2. Ver ressalva na página inicial.

Q11 e Q12: respostas e fontes por subitem na seção seguinte.

Versão D

Questões objetivas e aula correspondente

Q01 · Alternativa A — Boxplot e regra de Tukey

$IQR = 45 - 25 = 20$ mm; limite = $45 + 1,5 \times 20 = 75$ mm. Outliers superiores ficam estritamente acima do limite.

Aula/material: S03, §2.1

Q02 · Alternativa B — Custos assimétricos e recall

Priorizar recall = $VP/(VP+FN)$, reduzindo falhas não detectadas; tolerar falsos alarmes conforme o custo de inspeção.

Aula/material: S01, custos assimétricos; S02, §2

Q03 · Alternativa C — Avaliação no CRISP-DM

Verificar se o modelo atende às metas de negócio antes de implantá-lo: fase 5, Avaliação.

Aula/material: S01, §3, fase 5; S04, §3

Q04 · Alternativa B — Acurácia em classes raras

$99.920/100.000 = 99,92\%$. Recall = 0%: nenhum defeito foi detectado.

Aula/material: S02, §2

Q05 · Alternativa C — Tipos de variáveis

Identificador: nominal; severidade: ordinal; contagem: discreta; medição física: contínua. Respeitar a ordem do enunciado.

Aula/material: S01, §1.2

Q06 · Alternativa A — Teste de Shapiro-Wilk

$0,125 > 0,05$: não rejeitar H_0 ; isso não comprova normalidade.

Aula/material: S05, p-valor e testes de normalidade

Q07 · Alternativa A — Medida robusta de centro

Mediana: menos sensível a valores extremos, representando melhor o valor típico nesse cenário.

Aula/material: S01, §1.3; S03, §2.1

Q08 · Alternativa B — Componentes de séries temporais

Tendência (mudança de longo prazo), sazonalidade (repetição regular) e ruído/resíduo (flutuação aleatória).

Aula/material: S07, §1.1

Q09 · Alternativa C — Associação de métricas

Sequência: 2–1–3–4. Recall: $VP/(VP+FN)$; precisão: $VP/(VP+FP)$; acurácia: $(VP+VN)/total$; F1: média harmônica de precisão e recall.

Aula/material: S02, §2

Q10 · ANULADA — Paradigmas de aprendizado

Resposta conceitual para estudo do aluno (questão anulada): Sequência: 3–2–1–4. Regressão linear: supervisionado/valor contínuo; árvore de classificação: supervisionado/classe; K-Means: não supervisionado/agrupamento; PCA: não supervisionado/redução dimensional.

Aula/material: Cobertura parcial: S04, §2. Ver ressalva na página inicial.

Q11 e Q12: respostas e fontes por subitem na seção seguinte.

Respostas discursivas esperadas

Aplicáveis às versões A, B, C e D. Cada item vale 0,90 ponto.

Q11(a) — Matriz de confusão e custo do erro

Considerando defeito como classe positiva, FP (tipo I) é reprovar uma peça boa; FN (tipo II) é liberar uma peça defeituosa. No cenário da prova, FN tende a ser mais grave por causar acidentes, recalls e prejuízos, enquanto FP gera reinspeção.

Aula/material: S02, §2; S01, custos assimétricos; S05, erros tipos I e II

Q11(b) — Limitação da acurácia

Acurácia = $(VP+VN)/total$ e pode ser dominada pela classe majoritária. Com 0,1% de defeitos, prever todas as peças como boas gera 99,9% de acurácia, mas $VP=0$ e $recall=0\%$. Avaliar recall, precisão, F1 e custos dos erros, além da acurácia.

Aula/material: S02, §2

Q12(a) — Robustez da mediana e do IQR

A mediana depende da posição central dos dados ordenados e o $IQR=Q3-Q1$ descreve os 50% centrais. São menos afetados por extremos. A média usa todos os valores e é deslocada pelos outliers; o desvio padrão usa desvios quadráticos e também cresce com extremos. Robustez não significa imunidade absoluta.

Aula/material: S01, §1.3; S03, §2.1

Q12(b) — Decisão sobre normalidade

Com $\alpha=0,05$, se $p<0,05$, rejeitar H_0 de normalidade; se $p\geq 0,05$, não rejeitar H_0 , sem provar que os dados são normais. A decisão orienta a avaliação dos pressupostos do método e, quando necessário, transformações ou métodos robustos/não paramétricos. Não obriga transformar toda variável nem invalida todo modelo de ML.

Aula/material: S05, p-valor e testes de normalidade

Referências ao material

Pasta-base: Ciencia de Dados

S01 — Semana 01 — Estatística e CRISP-DM

Ciencia de Dados/aulas/semana_01.ipynb

S02 — Semana 02 — Matriz de confusão e métricas

Ciencia de Dados/aulas/semana_02.ipynb

S03 — Semana 03 — EDA e preparação dos dados

Ciencia de Dados/aulas/semana_03.ipynb

S04 — Semana 04 — Random Forest e avaliação de ROI

Ciencia de Dados/aulas/semana_04.ipynb

S05 — Semana 05 — Inferência e testes de hipóteses

Ciencia de Dados/aulas/semana_05.ipynb

S07 — Semana 07 — Séries temporais

Ciencia de Dados/aulas/semana_07.ipynb

R — Cronograma: aprendizado supervisionado e não supervisionado

Ciencia de Dados/README.md

G — Guia de estudo da P1 — apoio complementar

Ciencia de Dados/GUIA_ESTUDO_P1.md

Numeração das semanas preservada conforme os arquivos existentes. As seções citadas permitem localizar o conteúdo sem depender de paginação dos notebooks.